

# 2026-os Nyelvi Modell Architektúrák: Technológiai Konvergencia és a Szub-Kvadratikus Forradalom

A mesterséges intelligencia fejlődése 2026-ra elérte azt a kritikus tömeget, ahol az architektúrális diverzitás már nem csupán elméleti lehetőség, hanem a gazdasági fenntarthatóság és a technológiai hatékonyság alapfeltétele. Míg a 2010-es évek végétől a transzformátor-architektúra szinte kizárólagos dominanciát élvezett, a jelenlegi piaci környezetben a „tisztá” transzformátorok mellett megjelentek és éretté váltak a szub-kvadratikus komplexitású megoldások, mint az állapottér-modellek (SSM) legújabb iterációi és a modernizált rekurens neurális hálózatok (RNN).<sup>1</sup> Ez az elemzés a 2026-ban irányadó technológiai megoldásokat vizsgálja, különös tekintettel azok hatékonyságára, népszerűségére és azokra a specifikus optimalizációs technikákra, amelyek lehetővé teszik a modellek skálázását a millió-tokenes tartományokba.

## A transzformátorok hegemoniája és a Transformer++ éra

A transzformátor-architektúra 2026-ban is a „frontvonalbeli” (frontier) modellek alapköve marad. Az olyan rendszerek, mint az OpenAI GPT-5.5, a Google Gemini 3.1 és az Anthropic Claude 4.7, továbbra is a figyelem-mechanizmusra (attention mechanism) építenek, de egy olyan továbbfejlesztett változatban, amelyet a szakirodalom gyakran „Transformer++” néven említ.<sup>3</sup> Ezek a modellek azért tudták megőrizni vezető szerepüket, mert a figyelem-mechanizmus képessége a tűpontos visszakeresésre (retrieval) és a komplex, többlépcsős érvelésre továbbra is felülmúlja a tömörítés-alapú alternatívákat.<sup>1</sup>

## A figyelem-alapú rendszerek evolúciója: GPT, Gemini és Claude

A 2026-os év nagy nyelvi modelljei (LLM) már nem csupán szöveges prediktorok, hanem multimodális érvelési motorok. A GPT-5.5 például egy olyan egységesített architektúrát használ, amely képes a szöveget, képet és hangot egyetlen rendszerben kezelni, kiküszöbölve a korábbi verziókra jellemző modális eltolódásokat.<sup>8</sup> A Gemini 3.1 Pro ezzel szemben a kontextusablak méretével tűnik ki, ahol az 1 és 2 millió token közötti tartomány vált az iparági standarddá, lehetővé téve teljes könyvtárak vagy hatalmas kódalapok egyidejű elemzését.<sup>9</sup> A transzformátorok dominanciáját az alábbi táblázatban bemutatott teljesítményadatok és elérhetőségi jellemzők támasztják alá 2026 első negyedében:

| Modell | Fejlesztő | Hozzáférés | Kontextusablak | Főbb Benchmark (GPQA Diamond) |
|--------|-----------|------------|----------------|-------------------------------|
|        |           |            |                |                               |

|                         |           |                |            |                              |
|-------------------------|-----------|----------------|------------|------------------------------|
| <b>GPT-5.5</b>          | OpenAI    | API, Chatbot   | 1M token   | 92,4% <sup>12</sup>          |
| <b>Gemini 3.1 Pro</b>   | Google    | API, Vertex AI | 2M token   | 94,3% <sup>9</sup>           |
| <b>Claude 4.7 Opus</b>  | Anthropic | API, Chatbot   | 1M token   | 91,3% <sup>12</sup>          |
| <b>Llama 4 Maverick</b> | Meta      | Nyílt súlyú    | 400K token | ~88% (becsült) <sup>13</sup> |
| <b>DeepSeek V3.2</b>    | DeepSeek  | Nyílt/API      | 256K token | 79,9% <sup>13</sup>          |

A transzformátor-alapú rendszerek sikere mögött nem csupán a nyers számítási kapacitás áll, hanem olyan matematikai és algoritmus szintű finomítások, amelyek kezelhetővé teszik a

figyelem-mechanizmus kvadratikus költségvonzatát. A kvadratikus komplexitás ( $O(n^2)$ ) azt jelenti, hogy a szekvencia hosszának megduplázása négyszerezzi a számítási és memóriaigényt.<sup>1</sup> Ennek ellensúlyozására a 2026-os rendszerek olyan eljárásokat integrálnak, mint a FlashAttention-3 és a Multi-head Latent Attention (MLA).

## Hatékonyaságnövelő algoritmusok: FlashAttention-3 és

### PagedAttention

A transzformátorok hatékonyságának egyik legfontosabb mérföldköve a FlashAttention-3 algoritmus, amely az NVIDIA Hopper és Blackwell GPU-architektúrák hardveres sajátosságait használja ki.<sup>16</sup> A technológia lényege a memória-hozzáférés (IO) optimalizálása: a figyelem-pontszámok és értékek számítását úgy csempézik (tiling), hogy azok teljesen elférjenek az on-chip SRAM-ban, minimalizálva a lassú globális memóriába (HBM) történő írásokat és olvasásokat.<sup>16</sup>

A FlashAttention-3 az aszinkronitást helyezi előtérbe, különválasztva a „producer” (adatokat betöltő) és „consumer” (számításokat végző) warpokat a GPU-n. Ez lehetővé teszi a mátrixszorzási és softmax műveletek átlapolását, ami 1,5–2,0-szeres sebességnövekedést eredményez a korábbi verziókhöz képest, miközben fenntartja a teljes numerikus ekvivalenciát a standard figyelem-mechanizmussal.<sup>16</sup> Ez az optimalizálás kritikus a Gemini 3.1 és Claude 4.7 szintű modelleknél, ahol a hosszú kontextusok kezelése során az IO-sávszélesség válik a fő szűk keresztmetszetté.

Ezzel párhuzamosan a PagedAttention technológia (amelyet a vLLM projekt tett népszerűvé) forradalmasította a Key-Value (KV) cache kezelést.<sup>17</sup> A hagyományos rendszerek egybefüggő memóriaterületeket foglaltak le a kontextus számára, ami óriási pazarláshoz vezetett a változó hosszúságú kérések és a belső fragmentáció miatt. A PagedAttention az operációs rendszerek lapozási technikáját alkalmazza: a KV cache-t rögzített méretű lapokra osztja, és dinamikusan képezi le a logikai token-pozíciókat a fizikai memóriacímekre. Ez a megközelítés a korábban elpazarolt GPU-memória 60–80%-át képes felszabadítani, lehetővé téve a kiszolgálási áteresztőképesség megduplázását.<sup>17</sup>

## A Mixture of Experts (MoE) mint a modern LLM-ek gazdasági kényszere

2026-ra a Mixture of Experts (MoE) architektúra vált az uralkodó paradigmává a 100 milliárd

feletti paraméterszámú modellek esetében. Ez a megközelítés választ ad a skálázási törvények azon dilemmájára, hogy miként lehet növelni a modell tudáskapacitását anélkül, hogy az inferencia-költségek az egekbe szöknének.<sup>2</sup>

## Strukturális felépítés és útválasztás

Az MoE modellek, mint a Mistral Large 3 vagy a DeepSeek-V3, nem egyetlen sűrű (dense) hálózatként működnek. Ehelyett a feed-forward rétegeket több független „szakértőre” (expert) osztják fel. Amikor egy token belép a rétegbe, egy útválasztó (router) hálózat dönti el, hogy melyik szakértő a legmegfelelőbb az adott információ feldolgozásához.<sup>4</sup> Például a DeepSeek-V3 671 milliárd összesített paraméterrel rendelkezik, de minden egyes token feldolgozásakor csak 37 milliárd paramétert aktivál.<sup>2</sup>

Ez a szelektivitás drasztikusan javítja az inferencia sebességét: egy 1 billió paraméteres MoE modell képes egy 50 milliárdos modell sebességével válaszolni, miközben megőrzi a nagyobb modell komplex érvelési képességeit.<sup>4</sup> Az MoE hatékonysága azonban nagyban függ a terheléelosztástól (load balancing); ha az útválasztó túl sok tokenet küld egyetlen szakértőhöz, az a hardveres kihasználtság csökkenéséhez és lassuláshoz vezet. Ennek elkerülésére a 2026-os rendszerek már dinamikus útválasztási stratégiákat és segédveszteség-függvényeket (auxiliary loss) használnak a tanítás során.<sup>17</sup>

Az alábbi táblázat szemlélteti az MoE és a sűrű modellek közötti hatékonysági különbségeket 2026-os mérések alapján:

| Architektúra típusa | Teljes paraméterszám | Aktív paraméterek (tokenenként) | Relatív tanítási költség | Inferencia áteresztőképesség |
|---------------------|----------------------|---------------------------------|--------------------------|------------------------------|
| Sűrű (Dense)        | 175B                 | 175B                            | 1.0x                     | 1.0x                         |
| MoE (8x22B)         | 141B                 | 39B                             | 0.4x                     | 2.8x <sup>14</sup>           |
| DeepSeek MoE        | 671B                 | 37B                             | 0.25x                    | 4.5x <sup>2</sup>            |

## Multi-head Latent Attention (MLA) és a KV cache redukció

A transzformátorok memóriaigényének csökkentésére a DeepSeek-V2-vel bevezetett és a V3-ban tökéletesített MLA technológia jelenti a legkorszerűbb megoldást 2026-ban.<sup>19</sup> A hagyományos Multi-head Attention (MHA) minden fejhez külön kulcs- és érték-tenzorokat tárol a KV cache-ben, ami a kontextus növekedésével lineárisan emészti fel a GPU memóriáját. Az MLA ezzel szemben egy alacsony rangú (low-rank) tömörítést alkalmaz: a token információit egy apró látens vektorba vetíti, és csak a számítás pillanatában „rekonstruálja” a szükséges kulcsokat és értékeket.<sup>20</sup>

A DeepSeek jelentése szerint ez a megoldás a KV cache méretét elképesztő mértékben, 93,3%-kal csökkentette a hagyományos MHA-hoz képest.<sup>20</sup> Bár ez némi plusz számítási költséggel jár a rekonstrukció miatt, a memóriabandwidth-megtakarítás annyira jelentős, hogy lehetővé teszi a modellek számára az extrém hosszú kontextusok kezelését akár fogyasztói kategóriájú hardvereken is.<sup>19</sup>

# A Mamba-forradalom: Lineáris komplexitás és az állapottér-modellek visszatérése

Míg a transzformátorok a „brute-force” hatékonyságnövelés útját járják, egy új architektúrális család, az állapottér-modellek (SSM) — és különösen a Mamba — fundamentálisan változtatta meg a szekvencia-modellezésről alkotott elképzeléseket 2026-ra.<sup>1</sup> A Mamba legnagyobb

ígérete a lineáris komplexitás ( $O(n)$ ), ami azt jelenti, hogy a számítási idő és a memóriaigény a szekvencia hosszával arányosan növekszik, nem pedig annak négyzeteként.<sup>1</sup>

## A Mamba-3 technikai mélységei

A 2026 elején megjelent Mamba-3 representálja az SSM-technológia csúcsát. Ez a verzió már nem csupán a tanítási sebességre optimalizál (mint a Mamba-2), hanem az inferencia-első (inference-first) tervezési elvet követi.<sup>1</sup> A Mamba-3 három fő módszertani fejlesztést vezetett be, amelyek lehetővé teszik, hogy a modell minőségben felvegye a versenyt a transzformátorokkal:

- Exponenciális-Trapezoid Diszkretizáció:** A korábbi modellek által használt heurisztikus „exponenciális-Euler” sémát egy elméletileg megalapozottabb, általánosabb rekurens formulával váltották fel. Ez lehetővé teszi a modell számára, hogy komplexebb mintákat rögzítsen az időben, és implicit módon konvolúciót alkalmazzon a bemenetre, ami szükségtelenné teszi a korábbi rövid kauzális konvolúciókat.<sup>1</sup>
- Komplex-értékű állapotkövetés:** A Mamba-3 a rejtett állapotokat komplex számokként kezeli. Ez a váltás megoldotta az SSM-ek korábbi nagy gyengeségét: az állapotkövetési képességet (state-tracking). Míg a Mamba-2 gyakran elbukott egyszerű aritmetikai vagy paritás-ellenőrzési feladatokon, a komplex állapotok és a hozzájuk kapcsolódó „RoPE-trükk” (adatfüggő rotációs beágyazás) lehetővé teszik a precíz információ-megőrzést.<sup>1</sup>
- MIMO (Multi-Input Multi-Output) formuláció:** A korábbi modellek egybemenetes-egykimenetes (SISO) rendszerek voltak, ami korlátozta a párhuzamos feldolgozási képességet. A Mamba-3 mátrix-alapú frissítései lehetővé teszik több állapotcsatorna párhuzamos működtetését. Ez növeli az accuracy-t anélkül, hogy növelné a dekódolási késleltetést (latency), mivel a modern GPU-k kihasználatlan erőforrásait (Tensor Cores) vonja be a folyamatba.<sup>1</sup>

Az alábbi táblázat a Mamba-3 és a transzformátor-alapú Llama modellek összehasonlítását mutatja be 1.5B paraméteres skálán:

| Metrika                     | Llama-3.2-1B (Transformer) | Mamba-3 SISO | Mamba-3 MIMO (r=4)    |
|-----------------------------|----------------------------|--------------|-----------------------|
| Prefill Latency (16K token) | 12,17s                     | 16,22s       | 17,05s                |
| Decode Latency              | 976,50s                    | 140,61s      | 142,30s <sup>22</sup> |

|                               |         |          |                       |
|-------------------------------|---------|----------|-----------------------|
| (total)                       |         |          |                       |
| Átlagos Accuracy (Downstream) | 55,4%   | 56,0%    | 57,6% <sup>23</sup>   |
| Memóriaigény (KV cache)       | Növekvő | Konstans | Konstans <sup>1</sup> |

## A visszakeresési rés és a hibrid megoldások

Bár a Mamba-3 óriási előrelépés, a kutatások rámutattak egy fundamentális korlátra: az SSM-ek az információt tömörítik (compression), míg a transzformátorok explicit módon tárolják (database) a kontextust.<sup>1</sup> Ez azt jelenti, hogy a „tű a szénakazalban” (needle-in-a-haystack) típusú feladatoknál, ahol egy konkrét, eltemetett adatpontot kell visszakeresni, a transzformátorok továbbra is fölényben vannak.<sup>1</sup>

A megoldást 2026-ban a hibrid architektúrák jelentik. Az olyan modellek, mint az AI21 Labs által fejlesztett Jamba, 1:7 arányban kombinálják a transzformátor (attention) és a Mamba rétegeket.<sup>2</sup> Ez a hibridizáció lehetővé teszi, hogy a rendszer a figyelem-mechanizmust használja a pontos visszakereséshez, miközben az SSM rétegek végzik a hatékony szekvencia-modellezést, ami 256K-s kontextus mellett is 3-szoros áteresztőképességet biztosít a tiszta transzformátorokhoz képest.<sup>2</sup>

## RWKV-7 Goose: A rekurens modellek reneszánsza

Az RWKV (Receptance Weighted Key Value) architektúra 2026-ra a transzformátorok legkomolyabb nyílt forráskódú alternatívájává nőtte ki magát. Az RWKV különlegessége, hogy matematikailag transzformátorként tanítható (párhuzamosan), de RNN-ként (szekvenciálisan) futtatható az inferencia során.<sup>26</sup>

## A dinamikus állapotfejlődés és a Generalized Delta Rule

Az RWKV-7, kódneven „Goose”, 2025 márciusi megjelenése óta új standardot állított fel a rekurens modellezésben. A legfontosabb technikai újítása a **Generalized Delta Rule**, amely túllép a korábbi lineáris figyelem korlátain.<sup>28</sup> Míg a transzformátorok és a korábbi RWKV verziók

a számítási komplexitás szempontjából a  $TC^0$  osztályba tartoztak, az RWKV-7 bizonyítottan képes minden szabályos nyelv felismerésére és komplex állapotkövetésre, ami elméletileg a transzformátorok fölé helyezi bizonyos logikai feladatokban.<sup>29</sup>

A Goose architektúra szakít a fix skaláris elévüléssel (decay). Ehelyett vektor-értékű kapuzást és adatfüggő „in-context learning” rátákat használ. Ez lehetővé teszi a modell számára, hogy a rejtett állapotában (hidden state) szelektíven írjon felül információkat. Ha a modell egy olyan információt kap, amely cáfolja a korábbiakat, a Delta Rule segítségével a hibajavító mechanizmus azonnal frissíti a belső memóriát, anélkül, hogy a teljes kontextust újra kellene olvasnia.<sup>29</sup>

## Hatékonyság és többnyelvűség

Az RWKV-7 egyik legnagyobb előnye a rendkívüli adat-hatékonyság. Az RWKV-7-World 2.9B paraméteres modellje olyan teljesítményt nyújt többnyelvű feladatokban, amely vetekszik a náluk sokkal több adaton tanított Llama-3.2 vagy Qwen-2.5 modellekkel.<sup>28</sup> Ez az architektúra különösen népszerű az alacsony erőforrású nyelvek és a speciális domén-specifikus

finomhangolások területén, mivel a „végtelen” kontextusablak ( $O(1)$ , memória tokenenként) és a konstans inferencia-idő ideálissá teszi valós idejű alkalmazásokhoz.<sup>26</sup>

Az RWKV-7 energiahatékonysága (Joules per token) szintén kiemelkedő, mivel kiküszöböli a transzformátorokra jellemző hatalmas memóriabandwidth-éhséget, amit a KV cache folyamatos olvasása okoz. Ez a „zöld AI” mozgalom egyik kedvenc architektúrájává tette 2026-ban.<sup>26</sup>

## Hagyományos hálózatok modern szerepben: CNN és LSTM az élszámításban

Bár a globális nyelvi modellezésben a transzformátorok és az SSM-ek dominálnak, a konvolúciós neurális hálózatok (CNN) és a Long Short-Term Memory (LSTM) egységek nem tűntek el, hanem speciális, hibrid szerepkörökbe kényszerültek, különösen az élszámítás (edge computing) és az IoT területén.<sup>34</sup>

### Lokális mintafelismerés és idősoros hibridek

A CNN-eket 2026-ban leggyakrabban „frontend” processzorként használják a multimodális LLM-ekben vagy speciális szövegosztályozási feladatokban. A CNN kiválóan alkalmas a lokális n-gram minták és lexikai jellemzők gyors kinyerésére, amit aztán egy LSTM vagy transzformátor réteg dolgoz fel a globális összefüggések megértéséhez.<sup>38</sup>

Egy reprezentatív példa a 2026-os hibrid architektúrákra a webes tartalomosztályozó rendszer, amely a következőképpen épül fel:

- **CNN réteg:** A szövegből kinyeri a lokális morfológiai és szintaktikai mintákat.
- **LSTM réteg:** Modellezi a szekvenciális struktúrát és a hosszú távú függőségeket.
- **Figyelem-mechanizmus:** Szelektíven fókuszál a leginformatívabb szövegrészekre. Ez a kombináció 0,98-as accuracy-t és 0,93-as F1-score-t ér el, megelőzve a tiszta BERT-alapú transzformátorokat az éles, valós idejű szűrési feladatokban.<sup>38</sup>

### Alkalmazás az ipari biztonságban és orvosi diagnosztikában

Az LSTM-ek 2026-ban is dominálnak az ipari IoT (IIoT) kiberbiztonsági rendszereiben. A Zero Trust architektúrák részeként a CNN-ek a hálózati forgalom „térbeli” mintázatait (packet structure) elemzik, míg az LSTM-ek az időbeli anomáliákat figyelik.<sup>35</sup> Ez a kettősség lehetővé teszi a komplex támadási szekvenciák felismerését 96%-os pontossággal, miközben a modell elég könnyű ahhoz, hogy közvetlenül az ipari vezérlőkön (edge devices) fusson.<sup>35</sup>

Hasonló hibridizáció figyelhető meg a jelnyelv-szöveg (Sign-to-Text) fordítóknál. Itt a 3D-CNN felel a dinamikus gesztusok (mozdulatok) felismeréséért, míg az LSTM a statikus jelek azonosításáért. Ez a megközelítés lehetővé teszi, hogy a rendszer real-time működjön

korlátozott erőforrású eszközökön, mint a Raspberry Pi 4B, 99,6%-os pontosságot érve el a dinamikus jelek esetében.<sup>34</sup>

## Optimalizációs stratégiák: PEFT, LoRA és a hatékonyság határai

A 2026-os modellfejlesztés központi kérdése nem az, hogy hogyan tanítsunk meg egy modellt a nulláról, hanem az, hogy hogyan adaptáljuk azt hatékonyan specifikus feladatokhoz. A Parameter-Efficient Fine-Tuning (PEFT) módszerek váltak az iparági standarddá, lehetővé téve a 70 milliárd feletti paraméterszámú modellek testreszabását akár asztali munkaállomásokon is.<sup>41</sup>

### LoRA, QLoRA és az adapter-forradalom

A Low-Rank Adaptation (LoRA) a legszélesebb körben alkalmazott PEFT technika. A mechanizmus alapja az a hipotézis, hogy a modell súlyainak frissítése ( $\Delta W$ ) valójában egy alacsony rangú (low-rank) mátrixszal is leírható. Ahelyett, hogy a teljes  $d \times k$  dimenziós súlymátrixot frissítenék, két kisebb ( $d \times r$  és  $r \times k$ ) mátrixot tanítanak be, ahol  $r$  (a rang) jellemzően 8 és 64 között mozog.<sup>41</sup>

A 2026-ban használt legfontosabb PEFT variánsok jellemzőit az alábbi táblázat foglalja össze:

| Technika         | Mechanizmus                 | Memóriaigény (7B modell) | Főbb jellemző                                   |
|------------------|-----------------------------|--------------------------|-------------------------------------------------|
| Full Fine-Tuning | Minden paraméter frissül    | 100-120 GB VRAM          | Maximális minőség, óriási költség <sup>41</sup> |
| LoRA             | Alacsony rangú adapterek    | 24-32 GB VRAM            | Nullás inferencia késleltetés <sup>41</sup>     |
| QLoRA            | 4-bit kvantálás + LoRA      | 12-20 GB VRAM            | Fogyasztói GPU-n is fut <sup>41</sup>           |
| DoRA             | Súly-magnitúdó dekompozíció | ~28 GB VRAM              | Jobb konvergencia, mint a LoRA                  |
| OLoRA            | QR dekompozíció alapú init  | ~26 GB VRAM              | Stabilabb tanítás <sup>45</sup>                 |

A QLoRA 2026-ban különösen fontossá vált, mivel a 4-bit NormalFloat (NF4) kvantálás segítségével egy 65-70 milliárd paraméteres alapmodell súlyai mindössze 33-35 GB memóriát foglalnak el, így az egész folyamat belefér egyetlen 48 GB-os kártyába (pl. L40S vagy RTX 6000 Ada).<sup>41</sup> A kutatások igazolták, hogy a kvantált alapmodell és a teljes precíziójú adapterek kombinációja elhanyagolható (kevesebb mint 1%) pontosságvesztéssel jár a teljes tanításhoz képest.<sup>43</sup>

### A skálázható tanítási infrastruktúra

A tanítás során alkalmazott optimalizációk nem állnak meg a PEFT-nél. A 2026-os rendszerek olyan megoldásokat is integrálnak, mint:

- **Speculative Decoding:** Egy apró „draft” modell (például egy 1B paraméteres Mamba) előrevetít egy tokensort, amit a nagy célmodell (például GPT-5.5) egyetlen lépésben verifikál. Ez 2-3-szoros sebességnövekedést eredményez az inferencia során.<sup>2</sup>
- **Double Quantization:** A QLoRA részeként nemcsak a súlyokat, hanem a kvantálási konstansokat is kvantálják, ami további értékes megabyte-okat takarít meg a GPU memóriájában.<sup>41</sup>
- **Paged Optimizers:** Ha a GPU memória elfogy, az optimalizáló állapotait (optimizer states) ideiglenesen a CPU memóriába mozgatják, megakadályozva az „Out of Memory” hibákat a kritikus tanítási szakaszokban.<sup>43</sup>

## Kontextus-mérnökség és a hosszú szekvenciák kezelése

2026-ban a kontextusablak mérete vált az LLM-ek legfontosabb megkülönböztető jegyévé. A Google Gemini 3.1 Pro 2 millió tokenes képessége és az Anthropic Claude 4.7 1 millió tokenes ablaka olyan új használati módokat nyitott meg, amelyek korábban elképzelhetetlenek voltak.<sup>9</sup>

### Ring Attention és a megosztott figyelem

A transzformátorok millió-tokenes tartományba történő skálázásának egyik kulcsa a Ring Attention technológia. Ez a módszer a figyelem-mechanizmus számításait több GPU között osztja meg egy gyűrű topológiában. Ahelyett, hogy minden GPU-nak tárolnia kellene a teljes KV cache-t, a tokeneket körbeadják a hálózaton, így a memóriaigény eloszlik a fürt (cluster) összes egysége között.<sup>20</sup> Bár ez jelentős hálózati sávszélességet igényel, lehetővé teszi az elméletileg végtelen kontextus kezelését transzformátorokkal is, megőrizve a tökéletes visszakeresési képességet.<sup>15</sup>

Az alábbi táblázat a kontextus-kezelési technológiák összehasonlítását mutatja 2026-os mérések alapján:

| Technológia        | Típus                    | Maximális kontextus (stabil)  | Memóriaigény skálázódása | Visszakeresési pontosság |
|--------------------|--------------------------|-------------------------------|--------------------------|--------------------------|
| Standard Attention | Transzformátor           | 32K - 128K                    | Kvadrátikus ( $O(n^2)$ ) | 100%                     |
| Sparse Attention   | Transzformátor++         | 128K - 512K                   | Szub-kvadrátikus         | 92-95%                   |
| Ring Attention     | Elosztott Transzformátor | 1M - 10M+                     | Lineáris (per GPU)       | 100% <sup>20</sup>       |
| Mamba-3 (SSM)      | Állapottér-modell        | 1M+                           | Konstans ( $O(1)$ )      | 85-90% <sup>1</sup>      |
| RWKV-7 (Goose)     | Rekurens                 | Indefinite (8K-16K tökéletes) | Konstans ( $O(1)$ )      | 88-92% <sup>28</sup>     |



## A „Lost in the Middle” jelenség leküzdése

A hosszú kontextusú modellek egyik klasszikus problémája volt, hogy az információkat a szöveg közepén hajlamosak voltak elfelejteni. 2026-ra ezt két fő módon orvosolták:

1. **RULER Benchmark:** Egy új kiértékelési standard, amely kifejezetten a többszörös tű-a-szénakazalban visszakeresést, az aggregációt és a kontextus-követést méri, kényszerítve a fejlesztőket a középső tartományok optimalizálására.<sup>13</sup>
2. **KV Cache Re-consolidation:** Bizonyos architektúrák (például a legújabb Claude iterációk) in-place újraírják a KV cache szegmenseit, kiemelve a releváns részeket és tömörítve a zajt, ami javítja az érvelési képességet a hosszú dokumentumok elemzése során.<sup>48</sup>

## Energiahatékonyság és a fenntartható mesterséges intelligencia

Az AI modellek energiafogyasztása 2026-ban már nem csupán környezetvédelmi, hanem szigorú szabályozási kérdés is (Green AI). Az inferencia-költségek optimalizálása során a „token per Joule” mutató vált a legfontosabbá.<sup>26</sup>

### Inferencia-költségek összehasonlítása

A kutatások kimutatták, hogy a transzformátorok inferenciája rendkívül energiaigényes a KV cache folyamatos mozgatása miatt. Egy 70B paraméteres transzformátor modell 1 millió tokenes kontextus mellett nagyjából 320 GB GPU memóriát igényelne csak a KV cache tárolására, ami több H100-as kártyát jelent.<sup>2</sup> Ezzel szemben a Mamba és RWKV alapú rendszerek energiaigénye hosszú szekvenciák esetén akár 80-90%-kal alacsonyabb lehet, mivel nem igényelnek KV cache-t.<sup>15</sup>

Az energiafelhasználást befolyásoló tényezők 2026-ban:

- **Hardware-Aware Neural Architecture Search (NAS):** Automatizált keresés olyan modellek után, amelyek az adott hardveren (pl. mobil chipen vagy szerver GPU-n) a legmagasabb kihasználtságot (60-75% hatékonyság) érik el.<sup>46</sup>
- **Mixed-Precision Quantization:** A modell különböző rétegei különböző pontossággal (INT8, FP16, vagy akár 2-bit a nem kritikus rétegeknél) működnek, optimalizálva a teljesítmény/energia arányt.<sup>20</sup>
- **TokenPowerBench:** Az első olyan átfogó keretrendszer, amely Joules/token alapon méri a modellek hatékonyságát a prefill és a decode fázisokban elkülönítve, segítve a fejlesztőket az energia-szűk keresztmetszetek azonosításában.<sup>40</sup>

## Benchmarkok és a valódi teljesítmény mérése 2026-ban

A hagyományos benchmarkok (mint az MMLU vagy a GSM8K) 2026-ra telítődtek; a legtöbb modell 90% feletti eredményt ér el rajtuk, ami alkalmatlanná teszi őket a differenciálásra.<sup>13</sup>

Helyettük új, nehezebb tesztek kerültek előtérbe.

## A modern kiértékelési standardok

A modellek 2026-os rangsorolásánál a következő benchmarkok a mérvadóak:

- **GPQA Diamond:** PhD szintű tudományos érvelés (biológia, fizika, kémia), ahol a szakértők is csak 65-74%-ot érnek el, míg a Gemini 3.1 Pro már 94,3%-on áll.<sup>13</sup>
- **SWE-bench Verified:** Valós GitHub hibajegyek javítása kódmódosítással. Ez a „gold standard” a programozási képességek mérésére; a Claude 4.7 Opus itt 87,6%-os eredményt produkál.<sup>12</sup>
- **ARC-AGI 2:** Az absztrakt vizuális mintafelismerés tesztje, amely a valódi intelligenciát és a „fluid intelligence”-t méri, nem csak a mintafelismerést. A Gemini 3.1 Pro és a GPT-5.2 ezen a területen mutatnak jelentős fejlődést (77% feletti pontszámok).<sup>9</sup>
- **AIME 2025:** Emelt szintű matematikai olimpia feladatok, ahol a Grok 4 és a Gemini 3.1 Pro már elérték a 100%-os szintet.<sup>13</sup>

## Konkrét alkalmazási területek és iparági példák

Az architektúrák közötti választást 2026-ban a konkrét üzleti igény határozza meg. Az alábbiakban bemutatunk néhány kritikus iparági alkalmazást, ahol az említett modellek bizonyítják létjogosultságukat.

### Kutatás-fejlesztés és dokumentum-analízis

A Gemini 3.1 Pro 2 millió tokenes ablaka forradalmasította a jogi és orvosi kutatást. Egy jogi iroda képes egyetlen promptban feltölteni egy évtizednyi peranyagot, és a modell nemcsak visszakeresi a releváns precedenseket, hanem összefüggéseket talál a tanúvallomások között több ezer oldalnyi távolságban.<sup>8</sup> Itt a transzformátor figyelem-mechanizmusa és a Ring Attention biztosítja, hogy egyetlen apró részlet se vesszen el a „tömörítés” során.

### Valós idejű kódolási ágensek

A szoftverfejlesztésben a Claude 4.7 Opus vált az uralkodóvá, köszönhetően az SWE-bench-en mutatott kiváló teljesítményének és a precíz utasításkövetésnek (IFEval).<sup>9</sup> A kódolási ágensek hibrid architektúrát használnak: egy Mamba-alapú modellt a kód folyamatos, kis késleltetésű kiegészítéséhez (streaming auto-complete), és egy nagy transzformátor modellt (Claude) a komplex architektúrális döntésekhez és a végső kód-ellenőrzéshez.<sup>1</sup>

### Élszámítás és On-device AI

A mobiltelefonokon és hordozható eszközökön (pl. Apple Intelligence 2026-os verziója vagy az OpenClaw variánsok) a TinyLlama és a Phi-4-mini-flash-reasoning dominál.<sup>2</sup> Ezek a modellek 15-40 millió paraméter közötti méretben optimalizálják a hardver kihasználtságát, és gyakran 75%-ban Mamba rétegekből állnak, hogy 10-szeres áteresztőképességet biztosítsanak minimális akkumulátor-használat mellett.<sup>2</sup>

Az alábbi táblázat az élszámítási modellek teljesítményét mutatja be:

| Modell        | Paraméterek | Optimalizáció | Fogyasztás (Watt) | Inferencia sebesség (tokens/sec) |
|---------------|-------------|---------------|-------------------|----------------------------------|
| Phi-4-mini    | 1.3B        | 75% Mamba     | 2-5W              | 120+ t/s <sup>2</sup>            |
| TinyLlama-v2  | 1.1B        | INT4 Quant    | 1-3W              | 90+ t/s <sup>46</sup>            |
| MiMo-V2-Flash | 2.5B        | MoE + Mamba   | 4-8W              | 150+ t/s <sup>3</sup>            |

## Összegzés és konklúziók

A 2026-os év a nyelvi modell architektúrák tekintetében a konvergencia és a specializáció éve. A transzformátorok (Transformer++, MoE, MLA) megőrizték vezető szerepüket, mint a „legokosabb” modellek, amelyek a legmagasabb szintű érvelést és pontos visszakeresést igénylő feladatokban verhetetlenek.<sup>2</sup> Az olyan technológiák, mint a FlashAttention-3 és a PagedAttention, elérték a figyelem-mechanizmus elméleti határait, fenntarthatóvá téve a transzformátorok dominanciáját a felhőalapú nagyvállalati szolgáltatásokban.<sup>16</sup> Ugyanakkor az állapotér-modellek, különösen a Mamba-3, bizonyították, hogy a szub-kvadratikus skálázás nem jár szükségszerűen a minőség drasztikus romlásával.<sup>1</sup> A Mamba-3 MIMO formulációja és a komplex állapotkövetés áthidalta a korábbi „logikai szakadékok”, lehetővé téve az SSM-ek számára, hogy komoly alternatívát jelentsenek a transzformátorokkal szemben a hosszú kontextusú és valós idejű alkalmazásoknál.<sup>1</sup> Az RWKV-7 Goose pedig a rekurens modellek erejét mutatta meg, ahol az elméleti kifejezőerő túlszárnyalhatja a transzformátorokét is, miközben az energiahatékonyság terén új mércét állít fel.<sup>28</sup>

A jövő egyértelműen a hibrid modelleké. Az iparági trendek azt mutatják, hogy a legsikeresebb rendszerek (mint a Jamba vagy a Qwen3-Next) kombinálják a transzformátorok „adatbázis-szerű” pontos memóriáját az SSM-ek és RNN-ek hatékony szekvencia-feldolgozásával.<sup>2</sup> Ez a szimbiózis teszi lehetővé az AI-ügynökök számára, hogy egyszerre legyenek intelligensek, gyorsak és költséghatékonyak, legyen szó egy globális kutatóhálózatról vagy egy zsebben hordható személyi asszisztensről. A fejlesztők számára a kulcs nem egyetlen architektúra kiválasztása, hanem az optimalizációs technikák (LoRA, QLoRA, MLA, FlashAttention) és a megfelelő modell-útválasztási (routing) stratégiák tudatos alkalmazása az adott célfeladatnak megfelelően.

## Works cited

1. Mamba vs Transformer: The Real Shift in AI Architecture (2026) | by KOMILJON MUKHAMMADIEV - Medium, accessed April 27, 2026, <https://medium.com/@uzbrainai/mamba-vs-transformer-the-real-shift-in-ai-architecture-2026-bf758ba278ec>
2. What Comes After Transformers: Hybrid AI Architecture in 2026 ..., accessed April 27, 2026, <https://philippdubach.com/posts/the-last-architecture-designed-by-hand/>

3. The best large language models (LLMs) in 2026 - Zapier, accessed April 27, 2026, <https://zapier.com/blog/best-llm/>
4. Transformer Architecture in 2026: From Attention to Mixture of Experts (MoE), accessed April 27, 2026, <https://dev.to/jintukumardas/transformer-architecture-in-2026-from-attention-to-mixture-of-experts-moe-3d46>
5. Transformer Architectures in 2026: Foundations, Code, and Practical Resources | by Angelo Sorte | Medium, accessed April 27, 2026, <https://medium.com/@angelosorte1/transformer-architectures-in-2026-foundations-code-and-practical-resources-88022b521369>
6. Repeat After Me: Transformers are Better than State Space Models at Copying, accessed April 27, 2026, <https://kempnerinstitute.harvard.edu/research/deeper-learning/repeat-after-me-transformers-are-better-than-state-space-models-at-copying/>
7. What Is Mamba 3? The State Space Model Architecture That Challenges Transformers, accessed April 27, 2026, <https://www.mindstudio.ai/blog/what-is-mamba-3-state-space-model>
8. Top LLMs in 2026: Ranking the Most Powerful AI Models - Whistler Billboards, accessed April 27, 2026, <https://www.whistlerbillboards.com/friday-feature/top-llms-2026/>
9. Top AI Models 2026: How To Choose The Best For You - Nodewave, accessed April 27, 2026, <https://www.nodewave.io/blog/top-ai-models-2026-guide-compare-choose-deploy>
10. Best Long Context LLMs January 2026: AI Models for Large Documents | WhatLLM, accessed April 27, 2026, <https://whatllm.org/blog/best-long-context-models-january-2026>
11. Gemini 3.1 Pro - Model Card - Google DeepMind, accessed April 27, 2026, <https://deepmind.google/models/model-cards/gemini-3-1-pro/>
12. AI Leaderboard 2026 - Compare Top AI Models & Rankings, accessed April 27, 2026, <https://llm-stats.com/>
13. LLM Benchmarks 2026: 30+ Models Ranked — MMLU, SWE-bench ..., accessed April 27, 2026, <https://iternal.ai/llm-selection-guide>
14. Top 50+ Large Language Models (LLMs) in 2026 - Exploding Topics, accessed April 27, 2026, <https://explodingtopics.com/blog/list-of-llms>
15. Benchmarking the Computational and Representational Efficiency of State Space Models against Transformers on Long-Context Dyadic Sessions - arXiv, accessed April 27, 2026, <https://arxiv.org/html/2601.01237v1>
16. FlashAttention-3: Fast and Accurate Attention with Asynchrony and Low-precision - NIPS papers, accessed April 27, 2026, [https://proceedings.neurips.cc/paper\\_files/paper/2024/file/7ede97c3e082c6df10a8d6103a2eebd2-Paper-Conference.pdf](https://proceedings.neurips.cc/paper_files/paper/2024/file/7ede97c3e082c6df10a8d6103a2eebd2-Paper-Conference.pdf)
17. Efficient Attention and Beyond: A Survey of Advances in Optimizing Transformer Inference, accessed April 27, 2026, <https://medium.com/@smartudit1/efficient-attention-and-beyond-a-survey-of-a>



### state-evolution

33. Tokens per Joule: How to Quantify and Reduce the Energy Footprint of Clinical LLM Inference - John Snow Labs, accessed April 27, 2026, <https://www.johnsnowlabs.com/tokens-per-joule-how-to-quantify-and-reduce-the-energy-footprint-of-clinical-llm-inference/>
34. Comparative Evaluation of LSTM and 3D CNN Models in a Hybrid ..., accessed April 27, 2026, <https://www.mdpi.com/2227-9709/13/2/27>
35. Explainable deep learning with CNN-LSTM and LIME for securing IIoT ecosystems - PeerJ, accessed April 27, 2026, <https://peerj.com/articles/cs-3454.pdf>
36. Comparison of LSTM and Transformer Models for Activities of Daily Living Recognition using In-Home Ambient Sensors | medRxiv, accessed April 27, 2026, <https://www.medrxiv.org/content/10.64898/2026.01.06.25342431v1.full-text>
37. A hybrid LSTM and transformer model for analyzing e-commerce user behavior and path optimization - PeerJ, accessed April 27, 2026, <https://peerj.com/articles/cs-3707/>
38. [2512.18475] Research on a hybrid LSTM-CNN-Attention model for text-based web content classification - arXiv, accessed April 27, 2026, <https://arxiv.org/abs/2512.18475>
39. A hybrid model based on CNN-LSTM for assessing the risk of increasing claims in insurance companies - PMC, accessed April 27, 2026, <https://pmc.ncbi.nlm.nih.gov/articles/PMC12190450/>
40. TokenPowerBench: Benchmarking the Power Consumption of LLM Inference - AAAI Publications, accessed April 27, 2026, <https://ojs.aaai.org/index.php/AAAI/article/view/40535/44496>
41. Fine-Tuning Infrastructure: LoRA, QLoRA, and PEFT at Scale | Introl Blog, accessed April 27, 2026, <https://introl.com/blog/fine-tuning-infrastructure-lora-qlora-peft-scale-guide-2025>
42. LoRA & PEFT: Fine-Tuning Transformers | by Jaspinder kaur Walia | Feb, 2026 | Medium, accessed April 27, 2026, <https://medium.com/@jaspinderkaurwalia855/lora-peft-fine-tuning-transformers-3a7a9dd0f40c>
43. PEFT Methods Explained: LoRA, QLoRA, and Adapter-Based Fine-Tuning, accessed April 27, 2026, <https://pr-peri.github.io/blogpost/2026/02/27/blogpost-peft-models-explained.html>
44. Concepts - Fine-tuning language models for AI and machine learning workflows - Azure Kubernetes Service, accessed April 27, 2026, <https://learn.microsoft.com/en-us/azure/aks/concepts-fine-tune-language-models>
45. LoRA and PEFT: Efficient Fine-Tuning - Hugging Face, accessed April 27, 2026, <https://huggingface.co/learn/smol-course/unit1/3a>
46. [2601.03290] Lightweight Transformer Architectures for Edge Devices in Real-Time Applications - arXiv, accessed April 27, 2026, <https://arxiv.org/abs/2601.03290>

47. Best Large Context Window LLMs (2026) — Ranked by Benchmark Data | BenchLM.ai, accessed April 27, 2026, <https://benchlm.ai/best/large-context-window>
48. Bottlenecked Transformers: Periodic KV Cache Consolidation for Generalised Reasoning, accessed April 27, 2026, <https://arxiv.org/html/2505.16950v4>
49. How Mamba Beats Transformers at Long Sequences - Galileo AI, accessed April 27, 2026, <https://galileo.ai/blog/mamba-linear-scaling-transformers>
50. Benchmarks & Analysis - LLM Stats Blog, accessed April 27, 2026, <https://llm-stats.com/blog>
51. Gemini in Pro and long context — power file & code analysis, accessed April 27, 2026, <https://gemini.google/overview/long-context/>
52. 5 Cutting-Edge Natural Language Processing Trends Shaping 2026 - KDnuggets, accessed April 27, 2026, <https://www.kdnuggets.com/5-cutting-edge-natural-language-processing-trends-shaping-2026>